

# scrapy 突破反爬虫策略解析

## 爬虫与反爬虫基本概念

### 基本概念

**爬虫**-自动获取网站数据的程序，关键是批量的获取

**反爬虫**-使用技术手段防止爬虫程序的方法

**误伤**-反爬技术将普通用户识别为爬虫，如果误伤过高，效果再好也不能用

**成本**-反爬虫需要的人力和机器成本

**拦截**-成功拦截爬虫，一般拦截率越高，误伤率越高

误伤：由于学校、网吧等等用的是同一个公网 ip，而内部使用局域网，所以如果封禁了此 ip，会导致大量用户的流失，同时还有动态 ip 分配的存在，所以在反爬虫中，封禁 ip 的策略一般网站不会使用，最多是封禁 ip 一小段时间。

## 反爬目的

### 反爬虫的目的

初级爬虫-简单粗暴，不管服务器压力，容易弄挂网站

数据保护

失控的爬虫-由于某些情况下，忘记或者无法关闭的爬虫

商业竞争对手

## 突破反爬取的策略

### 1、随机切换用户代理 User-Agent

#### 简单实现

维护一个包含很多 User-Agent 的列表，每次在 Request yield 时，使用 random 函数随机选一个 User-Agent 传入 Request header。但是这种方法冗余度高，不利于复用。

#### Middleware 实现

自定义一个 Downloader Middleware，可以做到每次请求时，拦截一下，给请求头自动随机更换 User-Agent。

#### fake-useragent

维护的 user-agent 列表存放在在线网页上，随机生成 UA

#### 安装

```
pip install fake-useragent
```

## 用法

```
from fake_useragent import UserAgent
```

```
ua = UserAgent()
```

```
ua.ie
```

```
# Mozilla/5.0 (Windows; U; MSIE 9.0; Windows NT 9.0; en-US);
```

```
ua.msie
```

```
# Mozilla/5.0 (compatible; MSIE 10.0; Macintosh; Intel Mac OS X 10_7_3; Trident/6.0)'
```

```
ua['Internet Explorer']
```

```
# Mozilla/5.0 (compatible; MSIE 8.0; Windows NT 6.1; Trident/4.0; GTB7.4; InfoPath.2; SV1; .NET CLR 3.3.69573; WOW64; en-US)
```

```
ua.opera
```

```
# Opera/9.80 (X11; Linux i686; U; ru) Presto/2.8.131 Version/11.11
```

```
ua.chrome
```

```
# Mozilla/5.0 (Windows NT 6.1) AppleWebKit/537.2 (KHTML, like Gecko) Chrome/22.0.1216.0 Safari/537.2'
```

```
ua.google
```

```
# Mozilla/5.0 (Macintosh; Intel Mac OS X 10_7_4) AppleWebKit/537.13 (KHTML, like Gecko) Chrome/24.0.1290.1 Safari/537.13
```

```
ua['google chrome']
```

```
# Mozilla/5.0 (X11; CrOS i686 2268.111.0) AppleWebKit/536.11 (KHTML, like Gecko) Chrome/20.0.1132.57 Safari/536.11
```

```
ua.firefox
```

```
# Mozilla/5.0 (Windows NT 6.2; Win64; x64; rv:16.0.1) Gecko/20121011 Firefox/16.0.1
```

```
ua.ff
```

```
# Mozilla/5.0 (X11; Ubuntu; Linux i686; rv:15.0) Gecko/20100101 Firefox/15.0.1
```

```
ua.safari
```

```
# Mozilla/5.0 (iPad; CPU OS 6_0 like Mac OS X) AppleWebKit/536.26 (KHTML, like Gecko) Version/6.0 Mobile/10A5355d Safari/8536.25
```

```
# and the best one, random via real world browser usage statistic
```

```
ua.random
```

```
ua.update()
```

参考一下源码自带的用户代理 Downloader Middleware:

```
site-package/scrapy/downloadermiddlewares/useragent.py
```

```
"""Set User-Agent header per spider or use a default value from settings"""
```

```
from scrapy import signals
```

```

class UserAgentMiddleware(object):
    """This middleware allows spiders to override the user_agent"""

    def __init__(self, user_agent='Scrapy'):
        self.user_agent = user_agent

    @classmethod
    def from_crawler(cls, crawler):
        o = cls(crawler.settings['USER_AGENT'])
        crawler.signals.connect(o.spider_opened, signal=signals.spider_opened)
        return o

    def spider_opened(self, spider):
        self.user_agent = getattr(spider, 'user_agent', self.user_agent)

    def process_request(self, request, spider):
        if self.user_agent:
            request.headers.setdefault(b'User-Agent', self.user_agent)

```

模仿写一个我们自己的随机更换的 Downloader Middleware, `middlewares.py` 中加入:

```

from fake_useragent import UserAgent

class UserAgentMiddleware(object):
    def __init__(self, user_agent=""):
        self.ua = UserAgent()

    def process_request(self, request, spider):
        print('===UserAgentMiddleware process_request===')
        if self.ua:
            # 显示当前使用的 useragent
            print("*****Current UserAgent:%s*****")
            print(self.ua.random)
            request.headers.setdefault('User-Agent', self.ua.random)

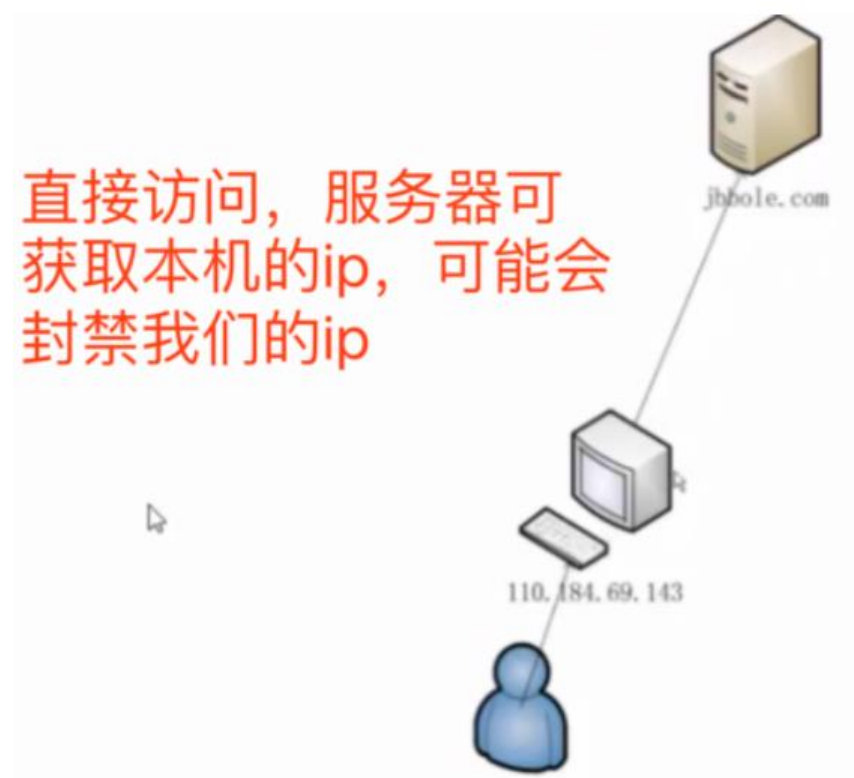
```

## 2 、随机更换代理 ip 策略


目前, 很多小区、公共 wifi 的 ip 是动态分配的, 当重启路由器、光猫后, 本机的对外 ip 可能会发生改变。所以, 若本机 ip 被封, 可重启以求换 ip。对外 ip 可直接百度查看:



## 直接访问网站



使用 ip 代理之后访问网站，可避免本机的 ip 暴露：



## 设置 ip 代理

```
request.meta['proxy'] = 'xxx.xx.xx.xxx:xx'
```

为了获取代理 ip, 我们可以前往西刺网获取免费的来试用或者付费购买一批可用的私密代理 IP:

```
PROXIES = [

    {'ip_port': '111.8.60.9:8123', 'user_passwd': 'user1:pass1'},

    {'ip_port': '101.71.27.120:80', 'user_passwd': 'user2:pass2'},

    {'ip_port': '122.96.59.104:80', 'user_passwd': 'user3:pass3'},

    {'ip_port': '122.224.249.122:8088', 'user_passwd': 'user4:pass4'},

]
```

高匿代理：能将我们的本机 ip 完全隐藏，普通代理可能还是会将本机 ip 带给服务器

```
class RandomProxy(object):
    def process_request(self, request, spider):
        proxy = random.choice(PROXIES)

        if proxy['user_passwd'] is None:
            # 没有代理账户验证的代理使用方式
            request.meta['proxy'] = "http://" + proxy['ip_port']
        else:
            # 对账户密码进行 base64 编码转换
            base64_userpasswd = base64.b64encode(proxy['user_passwd'])
            # 对应到代理服务器的信令格式里
            request.headers['Proxy-Authorization'] = 'Basic ' +
base64_userpasswd
            request.meta['proxy'] = "http://" + proxy['ip_port']
```

### 3、动态网页的爬取

```
class WebDriverMiddleware(object):
```

```
    @classmethod
```

```
    def from_crawler(cls, crawler):
```

```
        s = cls()
```

```
        crawler.signals.connect(s.spider_opened, signal=signals.spider_opened)
```

```
        return s
```

```
    def process_request(self, request, spider):
```

```
        # 加载驱动
```

```
        print('=====process_request=====')
```

```
        browser = webdriver.PhantomJS()
```

```
        browser.get(request.url) # 加载网页
```

```
        data = browser.page_source # 获取网页文本
```

```
        data = data.encode('utf-8')
```

```
        browser.quit()
```

```
        return HtmlResponse(request.url, body=data, encoding='utf-8', request=request)
```

```
    def process_response(self, request, response, spider):
```

```
        return response
```

```
def process_exception(self, request, exception, spider):
    pass

def spider_opened(self, spider):
    spider.logger.info('Spider opened: %s' % spider.name)
```

## DOWNLOADER\_MIDDLEWARES 设置

最后设置 setting.py 里的 DOWNLOADER\_MIDDLEWARES，添加自己编写的下载中间件类。

```
DOWNLOADER_MIDDLEWARES = {
    'mySpider.middlewares.UserAgentMiddleware': 1,
    'mySpider.middlewares.RandomProxy': 100
}
```

## 4、禁用 cookies

特殊情况下防止某些网站根据 Cookie 来封锁爬虫。

```
COOKIES_ENABLED = False
```

## 5、设置下载延迟

1. # 下载延迟单位秒，下载器在下载同一个网站下一个页面前需要等待的时间。该选项可以用来限制爬取速度，减轻服务器压力。同时也支持小数：
2. # 该设定影响(默认启用的) RANDOMIZE\_DOWNLOAD\_DELAY 设定。默认情况下，Scrapy 在两个请求间不等待一个固定的值，而是使用 0.5 到 1.5 之间的一个随机值 \* DOWNLOAD\_DELAY 的结果作为等待间隔。
- 3.

```
DOWNLOAD_DELAY = 3
```



## 小结

### 防止爬虫被反主要有以下几个策略：

动态设置 User-Agent（随机切换 User-Agent，模拟不同用户的浏览器信息）

禁用 Cookies，有些网站通过 cookie 的使用发现爬虫行为

设置延迟下载（防止访问过于频繁，设置为 2 秒 或更高

使用 IP 地址池：VPN 和代理 IP，现在大部分网站都是根据 IP 来 ban 的。

## 附录：Settings

Scrapy 设置(settings)提供了定制 Scrapy 组件的方法。

### 内置设置参考手册

- `BOT_NAME`

默认: 'scrapybot'

当您使用 `startproject` 命令创建项目时其也被自动赋值。

- `CONCURRENT_ITEMS`

默认: 100

Item Processor(即 Item Pipeline) 同时处理(每个 response 的)item 的最大值。

- `CONCURRENT_REQUESTS`

默认: 16

Scrapy downloader 并发请求(concurrent requests)的最大值。

- `DEFAULT_REQUEST_HEADERS`

默认: 如下

```
{  
  
'Accept': 'text/html,application/xhtml+xml,application/xml;q=0.9,*/*;q=0.8',  
  
'Accept-Language': 'en',  
  
}
```

Scrapy HTTP Request 使用的默认 header。

- `DEPTH_LIMIT`

默认: 0

爬取网站最大允许的深度(depth)值。如果为 0，则没有限制。

- `DOWNLOAD_DELAY`

默认: 0

下载器在下载同一个网站下一个页面前需要等待的时间。该选项可以用来限制爬取速度，减轻服务器压力。同时也支持小数:

```
DOWNLOAD_DELAY = 0.25 # 250 ms of delay
```

默认情况下，Scrapy 在两个请求间不等待一个固定的值，而是使用 0.5 到 1.5 之间的一个随机值 \* `DOWNLOAD_DELAY` 的结果作为等待间隔。

- `DOWNLOAD_TIMEOUT`

默认: 180

下载器超时时间(单位: 秒)。

- **ITEM\_PIPELINES**

默认: {}

保存项目中启用的 pipeline 及其顺序的字典。该字典默认为空，值(value)任意，不过值(value)习惯设置在 0-1000 范围内，值越小优先级越高。

```
ITEM_PIPELINES = {  
'mySpider.pipelines.SomethingPipeline': 300,  
'mySpider.pipelines.ItcastJsonPipeline': 800,  
}
```

- **LOG\_ENABLED**

默认: True

是否启用 logging。

- **LOG\_ENCODING**

默认: 'utf-8'

logging 使用的编码。

- **LOG\_LEVEL**

默认: 'DEBUG'

log 的最低级别。可选的级别有: CRITICAL、 ERROR、 WARNING、 INFO、 DEBUG 。

- **USER\_AGENT**

默认: "Scrapy/VERSION (+<http://scrapy.org>)"

爬取的默认 User-Agent，除非被覆盖。

- **PROXIES:** 代理设置

示例:

```
PROXIES = [  
    {'ip_port': '111.11.228.75:80', 'password': ''},  
    {'ip_port': '120.198.243.22:80', 'password': ''},  
    {'ip_port': '111.8.60.9:8123', 'password': ''},  
    {'ip_port': '101.71.27.120:80', 'password': ''},  
    {'ip_port': '122.96.59.104:80', 'password': ''},  
    {'ip_port': '122.224.249.122:8088', 'password': ''},  
]
```

- `COOKIES_ENABLED = False`

禁用 Cookies